

PILAME: Plataforma de Inteligencia Legal y Analítica de Mercado Estatal

Vinces León, Sebastián Alonso
Universidad del Pacífico
Lima, Perú

Saldaña Hidalgo, Diego Antonio
Universidad del Pacífico
Lima, Perú

Rodríguez Verástegui, Diego Joaquín
Universidad del Pacífico
Lima, Perú

Scarpati Pérez, Gianfranco Emanuele
Universidad del Pacífico
Lima, Perú

Quiñones Vivas, Diego Alejandro
Universidad del Pacífico
Lima, Perú

Resumen—Este trabajo presenta el diseño e implementación de PILAME (Plataforma de Inteligencia Legal y Analítica de Mercado Estatal), un sistema orientado a facilitar el acceso e interpretación de normas legales peruanas en el contexto de las contrataciones públicas. La plataforma integra dos fuentes de datos: 1,454 normas del Congreso de la República (2020–2025) obtenidas del Diario Oficial El Peruano, y 62,608 registros de contratos del Sistema Electrónico de Contrataciones del Estado (SEACE). Ambas fuentes son procesadas mediante un pipeline de Procesamiento de Lenguaje Natural (NLP) que clasifica semánticamente cada documento en uno de 15 sectores económicos, utilizando dos enfoques complementarios: TF-IDF con reglas léxicas de alta precisión, y embeddings semánticos densos con el modelo SBERT. Los documentos clasificados se almacenan en MongoDB Atlas como colecciones JSON estructuradas. La capa de consulta expone estas colecciones a través de una interfaz conversacional potenciada por Gemini, que interpreta consultas en lenguaje natural y genera respuestas contextualizadas sobre el marco normativo aplicable. El sistema habilita dos modalidades de uso: recuperación de normas por dominio temático, y análisis de compatibilidad normativa sobre nuevas contrataciones presentadas en PDF, identificando leyes, decretos legislativos, decretos supremos y resoluciones relevantes para cada caso.

Index Terms—Big Data, Apache Spark, NLP, SEACE, MongoDB, Gemini, Contrataciones Públicas, Regulación Legal.

I. INTRODUCCIÓN

I-A. Presentación del Caso de Estudio

En el Perú, las normas legales regulan directamente las condiciones bajo las cuales el Estado contrata bienes, servicios y obras con el sector privado. Estas normas determinan qué sectores reciben prioridad presupuestal, qué requisitos deben cumplir los proveedores y qué procedimientos rigen cada proceso de contratación. Sin embargo, existe una brecha estructural entre la forma en que las normas son redactadas, en lenguaje jurídico denso, disperso en múltiples cuerpos normativos publicados en El Peruano, y la capacidad real de los actores del mercado para identificarlas e interpretarlas en el contexto de un contrato concreto.

PILAME busca cerrar esta brecha mediante dos capacidades complementarias. La primera permite consultar qué normas vigentes aplican a un sector económico determinado. La segunda permite que un proveedor o entidad pública cargue el PDF de

una nueva contratación y obtenga automáticamente las normas del repositorio que resultan relevantes para ese contrato. Para soportar ambas funciones, el sistema construye un pipeline de clasificación semántica sobre las 62,608 contrataciones del SEACE y las 1,454 normas del Congreso, procesadas con técnicas de NLP y almacenadas en MongoDB Atlas.

I-B. Conceptos y Definiciones

I-B1. Big Data: El término Big Data designa el tratamiento de conjuntos de datos que superan la capacidad de herramientas convencionales, caracterizados por las dimensiones de volumen, variedad, velocidad, veracidad y valor. En este proyecto, el volumen surge de los más de 62,000 registros anuales del SEACE y del acervo acumulado de normas en El Peruano; la variedad, de la coexistencia de datos estructurados (contratos en formato tabular) y no estructurados (textos legales en PDF); y la velocidad, de la necesidad de incorporar nuevas normas y contratos de forma continua para mantener el repositorio actualizado.

I-B2. Procesamiento de Lenguaje Natural (NLP): El NLP comprende técnicas computacionales para extraer, representar y clasificar información a partir de texto no estructurado. En PILAME cumple dos funciones: asignar una categoría sectorial a cada norma y contrato, lo que permite relacionarlos entre sí, y analizar el contenido de una nueva contratación en PDF para identificar qué normas del repositorio son aplicables. Para la clasificación sectorial se implementan y comparan dos enfoques: TF-IDF con reglas léxicas construidas sobre vocabulario jurídico peruano, y embeddings semánticos con SBERT, que captura similitud de significado más allá de coincidencias léxicas exactas.

I-B3. Modelos de Lenguaje Generativos (LLM): Los modelos de lenguaje generativos son sistemas de inteligencia artificial capaces de comprender y producir texto en lenguaje natural a partir de un contexto proporcionado. En PILAME, Gemini actúa como motor de la capa de consulta: recibe el texto extraído de una contratación en PDF junto con el contenido del repositorio normativo en MongoDB, y genera una respuesta estructurada que identifica y explica las normas aplicables al caso concreto. Esta integración permite que

el sistema responda en lenguaje natural sin requerir que el usuario conozca la sintaxis de consulta de la base de datos.

I-B4. Sistema de Almacenamiento (Medallion): El sistema de almacenamiento sigue el patrón “medallion” en cuatro capas: Workload (ingesta de fuentes originales en XLSX y CSV), Landing (persistencia en formato Parquet sin transformar), Curated (datos limpios, tipados y clasificados sectorialmente) y Functional (datos listos para ser consumidos por la capa de consulta). Esta separación garantiza trazabilidad y permite re-ejecutar cualquier etapa del pipeline de forma independiente.

I-C. Objetivos

I-C1. Objetivo General: Desarrollar una plataforma que, a partir de la clasificación semántica de normas legales y contrataciones públicas, permita consultar qué leyes aplican a un sector económico determinado e identificar el marco normativo relevante para una nueva contratación presentada en PDF.

I-C2. Objetivos Específicos:

- Integrar datos del SEACE y normas legales de El Peruano en un Data Lake de cuatro capas procesado con Apache Spark.
- Implementar y comparar dos clasificadores sectoriales (TF-IDF con reglas léxicas y embeddings SBERT) para asignar cada documento a uno de 15 sectores económicos.
- Persistir los documentos clasificados en MongoDB Atlas en dos colecciones estructuradas (leyes y contrataciones), habilitando consultas de recuperación por dominio temático.
- Desarrollar un módulo de compatibilidad normativa que, dado el PDF de una nueva contratación, identifique las normas del repositorio aplicables a ese contrato.

II. ESTADO DEL ARTE

Diversos estudios han explorado la aplicación de Big Data y NLP en el análisis de documentos legales y su impacto en las contrataciones públicas.

El crecimiento sostenido de los datos abiertos gubernamentales ha impulsado el desarrollo de enfoques basados en Big Data orientados a mejorar la transparencia, eficiencia y control en la gestión pública. En este contexto, las bases de datos de contrataciones del Estado y los registros de modificaciones normativas constituyen fuentes de información de alto valor que, pese a su relevancia, suelen analizarse de manera independiente. Esta separación limita la comprensión de cómo los cambios en el marco legal influyen en los patrones de contratación pública, lo que evidencia la necesidad de sistemas capaces de integrar ambas fuentes mediante mecanismos de consulta inteligente.

Diversas investigaciones han abordado el análisis de contrataciones públicas desde una perspectiva cuantitativa, enfocándose en la detección de anomalías y riesgos de corrupción. En particular, Fazekas y Kocsis (2020) proponen un conjunto de indicadores derivados de datos masivos para identificar patrones atípicos en procesos de contratación, demostrando

el potencial del análisis de datos en este ámbito. Sin embargo, estos enfoques se centran principalmente en variables internas de las contrataciones, sin considerar el impacto de factores externos como las modificaciones normativas.

Por otro lado, el análisis de textos legales ha sido ampliamente desarrollado dentro del campo del procesamiento de lenguaje natural, debido a la complejidad y naturaleza no estructurada de los documentos jurídicos. Métodos tradicionales como TF-IDF han permitido representar documentos en espacios vectoriales, facilitando su comparación. No obstante, estos enfoques presentan limitaciones al no capturar adecuadamente el significado contextual del lenguaje jurídico.

En respuesta a estas limitaciones, enfoques más recientes han incorporado técnicas de aprendizaje profundo y representaciones semánticas avanzadas. En este sentido, el trabajo de Sugathadasa et al. (2018) propone un sistema de recuperación de documentos legales basado en *embeddings* y modelos de *deep learning*, permitiendo mapear documentos a espacios vectoriales donde la proximidad refleja similitud semántica. Este enfoque mejora significativamente la precisión en la recuperación de información, al superar las limitaciones de los métodos basados en coincidencias léxicas y permitir la identificación de relaciones conceptuales entre documentos legales.

Asimismo, Ashley (2017) explora la aplicación de la inteligencia artificial en el análisis de textos legales, destacando el uso de técnicas de minería de texto, clasificación automática y aprendizaje supervisado para estructurar grandes volúmenes de información jurídica. Este tipo de enfoques permite organizar documentos legales en categorías temáticas, facilitando su análisis y uso en sistemas computacionales.

En cuanto al análisis de datos, la clusterización se ha consolidado como una herramienta clave para identificar patrones latentes en grandes volúmenes de información. Algoritmos como K-means y *clustering* jerárquico permiten agrupar tanto datos estructurados como documentos textuales previamente vectorizados. En el contexto del presente estudio, estas técnicas resultan fundamentales para agrupar contrataciones públicas según sus características y modificaciones normativas según su contenido, facilitando el posterior cruce de información.

Por otra parte, los sistemas de recuperación de información han evolucionado hacia modelos que incorporan semántica y contexto. El modelo de espacio vectorial permite representar documentos y consultas en un mismo espacio matemático, facilitando la medición de la similitud mediante métricas como el coseno. Sobre esta base, los sistemas modernos han incorporado modelos semánticos que mejoran la relevancia de los resultados, especialmente en dominios complejos como el legal.

Adicionalmente, los sistemas de recomendación han demostrado ser efectivos para identificar relaciones entre elementos en grandes conjuntos de datos. Aunque tradicionalmente se han aplicado en otros dominios, su lógica puede adaptarse para vincular contrataciones con modificaciones normativas, considerando tanto la similitud semántica como la proximidad temporal.

A pesar de estos avances, la literatura evidencia una brecha significativa en la integración de estas áreas. Mientras que existen estudios enfocados en contratación pública y otros centrados en el análisis de textos legales, son escasos los trabajos que combinan ambos enfoques en un sistema unificado. En particular, la relación entre modificaciones normativas y patrones de contratación pública ha sido poco explorada desde una perspectiva basada en datos y técnicas de aprendizaje automático.

En este contexto, el presente proyecto propone un sistema de consulta que integra técnicas de representación semántica, clusterización y recuperación de información para identificar relaciones entre contrataciones públicas y modificaciones legales. Este enfoque permite no solo explorar patrones existentes, sino también facilitar el análisis del impacto normativo en la gestión pública, contribuyendo al desarrollo de herramientas más avanzadas en el ámbito del análisis de datos gubernamentales.

III. DISEÑO DEL CASO

III-A. Descripción del Conjunto de Datos

III-A1. Medio de Obtención: Los datos provienen de:

- **SEACE:** <https://bi.seace.gob.pe/pentaho/api/repos/%3Apublic%3Aportal%3Adataset.html/content?userid=public&password=key&pagina=contratos>
 - Corresponde al Sistema Electrónico de Contrataciones del Estado, donde la data recopila los contratos adjudicados a empresas privadas por distintos organismos del Estado de distintos años.
- **El Peruano:** normas legales en PDF (*Scraping*)
 - Corresponde al portal de leyes de la República del Perú, donde se recopila el conjunto de normas legales que son promulgadas por el Congreso de la República. A partir de esta fuente se extrajeron, mediante un proceso automatizado de extracción de datos, las leyes que utilizamos en nuestro análisis.
- **Repositorio del proyecto:** https://github.com/vinces1leon/GRUPO6_BDA.git

III-A2. Dimensión y Temporalidad del Dataset:

- **Dimensión:**
 - **Dataset de leyes:** Contiene 1,454 registros y 8 variables, las cuales corresponden a normas legales publicadas entre los años 2020 y 2025. Los principales campos son: Norma, Número, Publicación, Denominación (variable que se utiliza para clasificar el sector), Observaciones, link, etc. La cobertura temporal permite analizar normativa antigua y vigente, para poder evaluar los cambios y su impacto.
 - **Dataset de contrataciones públicas:** Contiene 62,463 observaciones y 24 variables, correspondientes únicamente al año 2025. Entre los campos más relevantes destacan `codigoentidad`, `codigoconvocatoria`, `descripcion_proceso`,

`monto_contratado_total`, `monto_contratado_item` y otros atributos administrativos vinculados al proceso contractual.

III-A3. Análisis Preliminar:

- **Predominancia del valor analítico de la variable Denominación:** Durante la exploración, destacó bastante el hecho de que la variable con mayor valor analítico es la que describe tanto el contrato como la ley, ya que contienen la información semántica suficiente para inferir el sector económico asociado.
- **Tratamiento de textos:** En ambos conjuntos de datos se observó presencia de caracteres especiales, formatos heterogéneos y diferencias de longitud textual. En el caso de las leyes predomina la terminología jurídica y administrativa, mientras que en contrataciones se presentan descripciones operativas, técnicas y abreviadas.
- **Amplia data temporal:** Gracias a la amplia data temporal en ambos conjuntos de datos es posible la comparación en materia de impacto analizando por intervalos temporales.

III-B. Metodología

III-B1. Estrategia de Extracción y Procesamiento:

1. **Técnicas aplicadas en la extracción de leyes:** Se implementó un proceso de *scraping* web en Python que permitió recorrer múltiples páginas de resultados, recuperar enlaces individuales y consolidar la información principal de cada norma en una base estructurada.
2. **Preprocesamiento textual:** Tanto para leyes como para contrataciones públicas, se aplicó una fase de preprocesamiento textual orientada a mejorar la calidad del dato. Esta etapa incluyó la normalización de mayúsculas y minúsculas, eliminación de signos innecesarios, caracteres especiales, espacios redundantes y términos administrativos con escaso valor semántico. Para el conjunto de datos de contrataciones también se realizó una depuración adicional sobre la descripción del proceso, con el fin de aislar el objeto principal del contrato y reducir el ruido generado por códigos internos o frases repetitivas.
3. **Clasificación de los Sectores:** Se definió una estructura temática compuesta por sectores económicos de referencia, entre ellos salud, educación, transporte e infraestructura, vivienda y saneamiento, energía, tecnología, minería, ambiente y seguridad.

III-B2. Sistema de almacenamiento del Data Lake y diseño por capas: El sistema PILAME se diseña bajo el sistema de almacenamiento Medallion de procesamiento por capas, paradigma consolidado en entornos de Big Data que organiza el flujo de datos en zonas de calidad. La implementación comprende cuatro capas funcionales: *Workload*, *Landing*, *Curated* y *Functional*, cada una con responsabilidades claramente delimitadas.

Capa Workload: Constituye el punto de entrada del pipeline y tiene como responsabilidad la ingesta de las fuentes

de datos crudas. Se procesan dos fuentes: el registro de contratos del Sistema Electrónico de Contrataciones del Estado (SEACE) provisto por la Organización Supervisora de las Contrataciones del Estado (OSCE), que comprende 62,608 registros en formato XLSX; y el compendio de normas del Congreso de la República del Perú para el período 2020–2025, estructurado en formato CSV con 1,461 registros.

Capa Landing: Una vez ingestados los datos con sus esquemas validados, esta tiene como propósito la persistencia de los datos, en este caso se guardó en formato Parquet con particionamiento explícito en dos fragmentos por dataset, este es un estándar de almacenamiento columnar binario que ofrece compresión eficiente. El particionamiento en dos archivos permite la paralelización de la lectura en la capa subsiguiente sin incurrir en overhead excesivo para el volumen de datos manejado. Esta capa actúa como zona de amortiguamiento entre las fuentes originales y el procesamiento analítico, garantizando que los datos crudos sean preservados en un formato eficiente e inmutable.

Capa Curated: Concentra la mayor complejidad del pipeline y comprende tres subfases: limpieza estructural, normalización lingüística y clasificación temática mediante aprendizaje automático no supervisado.

- **Limpieza:** Los contratos son filtrados eliminando registros con monto contratado igual o menor a cero y aquellos con fecha de publicación nula, garantizando la integridad analítica del dataset. Adicionalmente, se derivan columnas temporales (año y mes de publicación) y se genera una versión normalizada del campo de descripción del proceso (*desc_limpia*) mediante expresiones regulares que eliminan caracteres no alfabéticos. Para las normas, se aplica un filtro que conserva únicamente registros con número de ley en formato numérico estricto, se parsea la fecha de publicación al tipo `DateTime` y se eliminan duplicados exactos antes de cualquier clasificación.
- **Clasificación sectorial:** Se aborda como un problema de categorización textual no supervisada sobre 15 sectores de política pública peruana. Se implementan y comparan dos métodos: TF-IDF y el modelo preentrenado *paraphrase-multilingual-MiniLM-L12-v2* de la familia Sentence-BERT.

Capa Functional: Transforma los datos curados en estructuras de datos orientadas al consumo por aplicaciones externas. Esta capa comprende dos procesos diferenciados:

- **Enriquecimiento:** El primero es el enriquecimiento documental de las normas mediante *scraping* web y extracción de texto de documentos PDF. Para cada norma, se utiliza la URL del documento oficial desde el portal del Congreso mediante navegación HTTP, se descarga el documento en formato PDF y se extrae su contenido textual página a página mediante la biblioteca `pdfplumber`. El texto extraído es almacenado progresivamente en formato JSON para garantizar la recuperabilidad ante interrupciones de red.

- **Carga a MongoDB Atlas:** Se realiza la carga de dos colecciones separadas: *leyes*, que incorpora el texto completo de cada norma junto con sus metadatos y clasificación sectorial; y *contrataciones*, que desnormaliza el modelo relacional original en documentos jerárquicos con subdocumentos de tipo *items*, *vigencia*, *publicacion* y *clasificacion*. La carga se realiza en lotes de 5,000 documentos con manejo explícito de errores de escritura en *bulk*, y se crea un índice único sobre `codigo_contrato` para prevenir duplicados.

III-B3. Selección de Algoritmos y Métricas:

- **Asignación sectorial de los registros:** Se ha realizado una comparación de dos metodologías para la sectorización de las leyes y las contrataciones. Por un lado, se tiene TF-IDF, complementado con un pipeline híbrido de 12 reglas basadas en términos institucionales y normativos, realizándose la clasificación por similitud coseno. Por otro lado, se utiliza un modelo preentrenado “*paraphrase-multilingual-MiniLM-L12-v2*” de la familia de Sentence-BERT, el cual produce representaciones vectoriales densas de 384 dimensiones con capacidad semántica. Para cada sector se construye un centroide semántico como promedio normalizado de los *embeddings* de cinco frases representativas, clasificando cada texto por similitud coseno frente a la matriz de centroides.
- **Selección del mejor modelo:** La selección del método definitivo se realiza mediante un criterio cuantitativo basado en la entropía de la distribución sectorial resultante. Una distribución de mayor entropía indica mayor diversidad en la clasificación, lo que se interpreta como mayor capacidad discriminativa del clasificador. En el caso de este estudio, tanto para contratos como para las leyes, el algoritmo de TF-IDF tiene una mejor entropía que *paraphrase-multilingual-MiniLM-L12-v2*, obteniendo en contratos 3,275 frente a 0,685 y en leyes 3,353 frente a 3,092.
- **Categoría final:** El método con mayor entropía es seleccionado como `sector_final`, siempre que la tasa de registros ‘Sin clasificar’ del método supere el 5 %, condición que operacionaliza la preferencia por cobertura completa.

III-B4. Optimización e Implementación:

- **Mejora de rendimiento:** Con el objetivo de mejorar el rendimiento del modelo, se incorporó el uso de unigramas y bigramas, permitiendo identificar expresiones compuestas frecuentes como nombres institucionales, obras públicas o servicios especializados.
- **Velocidad de procesamiento e interpretabilidad:** Asimismo, la combinación entre reglas directas y similitud textual permitió equilibrar la velocidad de procesamiento, la interpretabilidad y la cobertura temática. Las reglas aceleran la clasificación de casos evidentes, mientras que la vectorización mejora la asignación en textos ambiguos o menos frecuentes.

- **Resultado final:** El sistema genera una categoría sectorial para cada ley y para cada proceso de contratación pública. Esta homologación temática permite relacionar ambas fuentes dentro de una misma estructura analítica, facilitando la identificación de normas legales potencialmente vinculadas con proyectos estatales del mismo sector económico.

III-B5. *Análisis Integrador:*

- **Agente Inteligente para Consulta Analítica:** Para complementar el análisis de datos realizado sobre las contrataciones públicas, se desarrolló un agente inteligente basado en Large Language Models (LLM) y bases de datos NoSQL. La solución fue implementada utilizando el modelo Gemini sobre una base de datos MongoDB que almacena información de contrataciones públicas y normativa legal.
- **Arquitectura del Agente:** La arquitectura del sistema sigue un enfoque de agentes con uso de herramientas (*Tool Calling*). Bajo este esquema, el modelo de lenguaje no accede directamente a la información, sino que selecciona dinámicamente funciones especializadas según la consulta realizada por el usuario. De esta manera, el agente es capaz de transformar preguntas formuladas en lenguaje natural en operaciones estructuradas sobre la base de datos.
- **Herramientas del Sistema:** El sistema incorpora cuatro herramientas principales. La primera permite realizar consultas simples sobre las colecciones de MongoDB mediante filtros y expresiones de búsqueda. La segunda ejecuta pipelines de agregación para efectuar operaciones analíticas complejas. La tercera herramienta procesa archivos CSV o Excel que contienen información de contrataciones públicas y los convierte a una estructura JSON normalizada compatible. Finalmente, la cuarta herramienta identifica normativa relacionada con una contratación específica mediante búsquedas semánticas sobre la colección de leyes.
- **Preparación y Normalización de Datos:** Durante la etapa de preparación de datos se desarrolló un proceso de transformación que convierte registros tabulares en documentos jerárquicos JSON. Este proceso normaliza tipos de datos, fechas y valores numéricos, además de organizar la información en subestructuras que representan la entidad contratante, vigencia contractual, clasificación sectorial, resoluciones e ítems asociados al contrato.
- **Estrategia de Recuperación de Normativa Relacionada:** Para la búsqueda de normativa relacionada se implementó una estrategia basada en conceptos regulatorios. En lugar de buscar coincidencias textuales exactas entre contratos y leyes, el agente identifica actividades económicas, dominios regulatorios y conceptos jurídicos asociados a cada contratación. Posteriormente, ejecuta consultas de agregación sobre la colección de leyes para recuperar aquellas normas potencialmente vinculadas con el objeto contractual. Este enfoque mejora significativa-

mente la recuperación de información jurídica relevante frente a métodos basados únicamente en coincidencias literales.

- **Flujo Operativo:** El flujo operativo del agente consiste en recibir una consulta en lenguaje natural, interpretar la intención del usuario mediante el modelo de lenguaje, seleccionar la herramienta adecuada, ejecutar la consulta correspondiente sobre MongoDB y generar una respuesta fundamentada en los datos obtenidos. Esta arquitectura permite combinar capacidades de inteligencia artificial generativa con análisis estructurado de grandes volúmenes de información pública, facilitando la exploración y comprensión de contrataciones estatales y del marco normativo asociado.

IV. RESULTADOS

IV-A. *Clasificación sectorial y distribución normativa*

La figura 1 muestra el módulo en operación sobre un caso real: el Contrato N° 00418-2025 - OEFA/OAD-UAB, suscrito entre el OEFA y un evaluador independiente por S/ 18,000.00. El sistema extrajo 26,414 caracteres del PDF de 8 páginas y, consultando la colección “leyes” en MongoDB Atlas mediante Gemini, identificó el marco normativo completo organizado en cuatro categorías.

En leyes: Código Civil, Ley N° 29325 (Fiscalización Ambiental), Ley N° 29783 (Seguridad y Salud en el Trabajo), Ley N° 30035 (Repositorio Digital) y Ley N° 26872 (Conciliación). En decretos legislativos: D.L. N° 1013 (creación del MINAM) y D.L. N° 1440 (Presupuesto Público). En decretos supremos: cinco reglamentos vinculados a las normas anteriores. En resoluciones: tres instrumentos institucionales de la OEFA relativos a la contratación de terceros evaluadores, seguridad laboral y gestión integrada.

Cabe destacar que PILAME no se limitó a recuperar las normas listadas en la Cláusula Primera del contrato, sino que identificó también instrumentos citados en cláusulas internas sobre obligaciones, propiedad intelectual y controversias, evidenciando la capacidad de Gemini para construir un mapa normativo completo a partir del contenido íntegro del documento.

IV-B. *Distribución de leyes por sector*

El gráfico de barras muestra la distribución de las 1,454 normas clasificadas en los 15 sectores del repositorio. El hallazgo más relevante es que aproximadamente 500 normas quedaron etiquetadas como “Sin clasificar”, constituyendo la categoría más grande con diferencia. Esto refleja directamente la limitación del clasificador ante denominaciones legales ambiguas o transversales que no activan ninguna regla léxica ni alcanzan el umbral mínimo de similitud coseno en TF-IDF.

Entre los sectores clasificados, Vivienda y Saneamiento lidera con alrededor de 210 normas, seguido por Seguridad (≈140), Educación (≈125) y Salud (≈115). Estos cuatro sectores concentran la mayor producción legislativa, lo que es consistente con su relevancia en la agenda pública peruana del periodo 2020–2025. Un bloque intermedio agrupa a Justicia

(≈90), Transporte (≈60) y Comercio (≈50). En el extremo inferior se encuentran sectores como Ambiente, Minería y Energía, con menos de 20 normas cada uno, lo que sugiere que su regulación se canaliza principalmente a través de decretos supremos y resoluciones ministeriales no incluidos en el repositorio actual, más que a través de leyes del Congreso.

V. CONCLUSIONES

PILAME demuestra que es viable integrar un pipeline de Big Data con un modelo de lenguaje generativo para construir un sistema de consulta normativa funcional. El pipeline sobre Apache Spark procesó exitosamente 62,608 contratos y 1,454 normas bajo una arquitectura medallón de cuatro capas, demostrando que fuentes heterogéneas —datos estructurados del SEACE y textos legales en PDF— pueden integrarse de forma trazable en un único flujo de procesamiento. La combinación de TF-IDF con reglas léxicas y embeddings SBERT resultó complementaria: el primero ofrece alta precisión en sectores con vocabulario institucional distintivo, mientras que el segundo captura mejor la similitud semántica en descripciones ambiguas.

La integración de MongoDB Atlas con Gemini como motor de consulta fue el componente más significativo del sistema. Probado sobre el Contrato N° 00418-2025 de la OEFA, Gemini no se limitó a recuperar las normas explícitamente listadas en el documento, sino que infirió el marco normativo completo a partir de su contenido íntegro, identificando instrumentos citados en cláusulas internas que un usuario no especializado difícilmente encontraría de forma manual. Esto valida el enfoque de combinar un repositorio clasificado semánticamente con un modelo generativo capaz de razonar sobre el contexto jurídico del documento.

El análisis de distribución sectorial reveló dos asimetrías relevantes. Por el lado normativo, Vivienda y Saneamiento concentra la mayor producción legislativa clasificada, mientras que sectores como Ambiente, Minería y Energía presentan menos de 20 normas, lo que sugiere que su regulación se canaliza por instrumentos fuera del alcance actual del repositorio. Por el lado contractual, Vivienda, Construcción y Saneamiento lidera con 15,835 adjudicaciones y el mayor monto total, evidenciando que una mayor densidad normativa no implica necesariamente una mayor actividad contractual.

VI. LIMITACIONES Y TRABAJO FUTURO

El sistema presenta seis limitaciones principales:

- El repositorio es estático y no se actualiza automáticamente ante nuevas publicaciones del SEACE o El Peruano.
- Aproximadamente el 34 % de las normas quedaron sin clasificar, reduciendo la cobertura real de las consultas temáticas.
- La fuente normativa se limita a leyes del Congreso, excluyendo decretos regionales y directivas del OSCE.
- La clasificación sectorial única genera omisiones en contratos transversales a varios sectores.




Figura 2. Leyes por sector



Figura 3. Prompt por API

- El módulo de compatibilidad falla ante PDFs escaneados sin reconocimiento óptico de caracteres (OCR).
- La ausencia de un conjunto de evaluación etiquetado impide medir con precisión el desempeño real de los clasificadores.




Figura 1. Gráfico de Burbujas

REFERENCIAS

- [1] K. D. Ashley, *Artificial Intelligence and Legal Analytics: New Tools for Law Practice in the Digital Age*. Cambridge University Press, 2017.
- [2] Congreso de la República del Perú, “Sistema Peruano de Información Jurídica – Portal de Leyes,” 2025. [En línea]. Disponible: <https://www.leyes.congreso.gob.pe/>
- [3] M. Fazekas y J. Kocsis, “Uncovering High-Level Corruption Risks in Public Procurement using Big Data,” *Government Information Quarterly*, vol. 37, no. 4, 2020.
- [4] Organismo Especializado para las Contrataciones Públicas Eficientes (OECE), “Portal de Datos Abiertos y Contrataciones Públicas,” 2025. [En línea]. Disponible: <https://www.gob.pe/oece>
- [5] I. Sugathadasa et al., “Legal Document Retrieval using Text Embeddings and Deep Learning,” en *Proceedings of the International Conference on Natural Language Processing*, 2018.